Perfis sonoros dos Hits da Billboard Hot 100

Grupo MPL09

Afonso Claudino · André Marques

Conjuntos de dados: Billboard Hot 100 (1958–2021) e Spotify Audio Features

Índice

Índice 2
1. Introdução 3
2. Preparação final dos dados 3
3. Metodologia 4
4. Resultados 5
4.1 Quatro perfis sonoros 5
4.2 Evolução dos perfis ao longo das décadas 5
5. Discussão 6
6. Conclusões 6
7. Declaração sobre o uso de ferramentas de IA 7
8. Referências 7
9. Anexos 7
Anexo A — Métricas de avaliação por k 7
Anexo B — Distribuição (%) dos clusters por década 7
Anexo C — Notas de reprodutibilidade 8

1. Introdução

O presente relatório prossegue o trabalho desenvolvido na primeira fase do projeto, na qual foram explorados dois conjuntos de dados públicos relativos à música popular dos Estados Unidos da América: o Billboard Hot 100 (a tabela semanal de êxitos, com cerca de 327 mil linhas correspondentes a aparições de músicas em determinada semana, entre 1958 e 2021) e o conjunto de características de áudio do Spotify (aproximadamente 29 mil músicas, cada uma descrita por atributos como danceability, energy, valence, acousticness ou tempo). Na fase exploratória, procedeu-se à avaliação da qualidade dos dados, tendo sido identificados valores em falta nas características de áudio do Spotify, registos duplicados e valores impossíveis ou mal estimados (tempo a 0 BPM e «double counting» acima de ~190 BPM, durações incorretas e um caso de loudness de +2,3 dB); formularam-se, então, as questões de investigação que orientam a presente análise.

Objetivo geral. O objetivo geral consiste em identificar, sem recurso a rótulos predefinidos, que perfis sonoros caracterizam os êxitos da Billboard e em compreender de que modo a prevalência desses perfis evoluiu ao longo das décadas. Definiram-se, para o efeito, as seguintes questões de investigação:

- **Q1.** Existirão grupos naturais e interpretáveis de músicas que são hits, definidos exclusivamente pelas suas características de áudio?
- **Q2.** Variará a composição desses grupos de forma sistemática ao longo do tempo, refletindo a evolução do registo sonoro dominante nas tabelas?

Estas questões retomam diretamente o relatório preliminar (Fase 1), no qual o grupo havia proposto investigar «padrões sonoros distintos para cada década» e determinar «quantos tipos de receita de hits» existem, tendo inclusivamente antecipado a ponderação das observações pela posição no chart. A vertente sazonal, igualmente proposta na Fase 1, é abordada de forma complementar; o presente relatório centra-se no eixo temporal por década e na caracterização dos perfis de êxito.

A natureza do problema, a procura de estrutura latente em dados desprovidos de variável-alvo, justifica o recurso à aprendizagem não supervisionada, concretamente ao agrupamento por K-means (clustering). A relação com a dimensão temporal é analisada a posteriori, mediante o cruzamento dos grupos obtidos com a década de cada observação.

2. Preparação final dos dados

Junção e unidade de análise. Os dois ficheiros foram unidos pela variável song_id através de uma junção interna (inner join), conservando-se apenas as músicas presentes no Hot 100 e dotadas de características de áudio. A unidade de análise adotada é a observação "música-semana": cada linha corresponde à presença de uma música numa semana específica do chart. Trata-se de uma opção deliberada, porquanto o objetivo não é descrever o catálogo musical em geral, mas antes o registo sonoro que efetivamente teve difusão e êxito em cada período. Uma música que permaneceu vinte semanas na tabela tem, por conseguinte, maior peso do que outra que nela figurou numa única semana.

Remoção de duplicados e identificadores. No conjunto de áudio aplicou-se dropDuplicates(song_id), garantindo uma única ficha por música, e removeram-se as colunas redundantes song e performer, já constantes do Billboard. Ao conjunto Billboard aplicou-se distinct(), eliminando registos repetidos. Os identificadores e os URL foram excluídos da análise, por carecerem de significado sonoro.

Seleção de variáveis. Das colunas disponíveis selecionaram-se dez características de áudio contínuas: danceability, energy, loudness, speechiness, acousticness, instrumentalness, liveness, valence, tempo e duração (ms). Foram excluídas as variáveis de desempenho na tabela (posição, semanas no chart e

posição-pico), por traduzirem o êxito comercial e não o registo sonoro; as variáveis redundantes ou de reduzida interpretabilidade (key, mode e time_signature); e a popularidade no Spotify, por constituir uma medida atual e não contemporânea do êxito. O critério orientador foi o de reter unicamente variáveis dotadas de relevância sonora, reduzida redundância e interpretabilidade clara.

Valores em falta e variável derivada. As observações sem qualquer das dez características foram removidas (na.drop). A partir de week_id derivou-se a década (1950s…2020s), utilizada exclusivamente como variável de leitura, não integra o agrupamento, de modo que os grupos sejam definidos unicamente pelo registo sonoro.

Ponderação pela posição no chart. Para que cada observação reflita a respetiva importância, atribuiu-se um peso $w = \lceil \sqrt{(101 - posição)} \rceil$, que varia entre 10 (lugares cimeiros) e 1 (posição 100). A compressão por raiz quadrada evita que o número 1 domine excessivamente, mantendo um rácio topo–fundo de 10:1. Dado que o K-means não admite pesos de forma nativa, replicou-se cada linha w vezes. O conjunto evoluiu de 284 136 observações música-semana para 2 053 341 observações ponderadas.

Padronização. As dez características apresentam escalas muito distintas (tempo em centenas de BPM, valence entre 0 e 1, duração em centenas de milhar de ms). Uma vez que o K-means recorre à distância euclidiana, aplicou-se o StandardScaler (média 0 e desvio-padrão 1) através de um Pipeline. Sem esta etapa, o tempo e a duração dominariam a distância, anulando o contributo das restantes variáveis.

3. Metodologia

Método escolhido. Aplicou-se o K-means (PySpark MLlib) às dez características padronizadas. Este método afigura-se adequado, porque as variáveis são contínuas, a noção de proximidade sonora é naturalmente euclidiana e o algoritmo apresenta boa escalabilidade perante milhões de observações ponderadas, vantagem decisiva num contexto de Big Data, no qual métodos como o agrupamento hierárquico (de complexidade quadrática) seriam inviáveis. Fixou-se a semente aleatória (seed=42) para assegurar a reprodutibilidade.

Escolha do número de clusters. Avaliaram-se valores de k de 2 a 8, combinando dois critérios: o método do cotovelo (WSSSE) e o coeficiente de silhueta (calculado sobre uma amostra de 10%, por razões de escala). A Figura 1 apresenta os resultados.

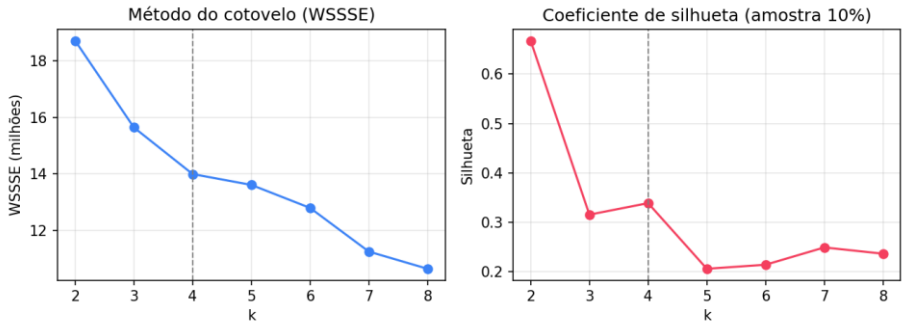


Figura 1 — Avaliação do número de clusters: cotovelo (WSSSE) e silhueta para k de 2 a 8.

A silhueta é máxima em k=2 (0,67); contudo, essa solução limita-se a distinguir, de forma grosseira, o registo acústico/antigo do conjunto das restantes observações, revelando escasso valor analítico. O WSSSE decresce acentuadamente até k=4, estabilizando a partir desse ponto (cotovelo), e a silhueta recupera ligeiramente em k=4 (0,34) face a k=3 (0,32). Privilegiando a interpretabilidade em detrimento

do ótimo numérico, fixou-se K=4, o menor número de grupos capaz de produzir perfis distintos e passíveis de designação. Trata-se de uma decisão fundamentada e discutida, e não arbitrária.

Avaliação da relação com o tempo. Concluído o agrupamento, cruzaram-se os grupos com a década (tabela de contingência) e mediu-se a força da associação através do V de Cramér. Optou-se por este indicador, em detrimento do valor-p do qui-quadrado, uma vez que a replicação por pesos inflaciona o n (cerca de 2 milhões), tornando qualquer valor-p artificialmente significativo; o V de Cramér constitui uma medida de dimensão do efeito (effect size) robusta à dimensão da amostra.

4. Resultados

4.1 Quatro perfis sonoros

O K-means com K=4 identifica quatro arquétipos claramente interpretáveis. A Tabela 1 sintetiza as médias (ponderadas, em escala original) das principais características por cluster.

Cluster (perfil)	Dance.	Energy	Acoust.	Instrum.	Valence	Tempo
C0 — Pop	0,73	0,68	0,16	0,01	0,73	112
C1 — Música Agitada	0,54	0,75	0,14	0,01	0,53	136
C2 — Instrumental	0,62	0,62	0,31	0,70	0,65	120
C3 — Acústico / orquestral	0,52	0,40	0,57	0,01	0,47	114

Tabela 1 — Perfil médio (ponderado) de cada cluster nas características mais distintivas.

- **C0 – Pop (dominante).** Valores elevados de danceability e valence e energia intermédia; corresponde ao registo sonoro tipicamente comercial, orientado para a difusão radiofónica. Constitui o maior grupo (859 mil observações ponderadas).
- **C1 – Música agitada.** Energia e cadência elevadas (136 BPM) e valores mais baixos de valence e danceability, abrange rock, eletrónica e pop mais enérgico.
- **C2 – Instrumental.** Distingue-se por uma instrumentalness muito elevada (0,70), singular entre os grupos; reúne temas instrumentais. É o menor grupo (57 mil) e encontra-se em declínio.
- **C3 – Acústico / orquestral.** Acousticness muito elevada (0,57) e valores baixos de energia e loudness — abrange baladas e o registo acústico/orquestral característico das primeiras décadas.

4.2 Evolução dos perfis ao longo das décadas

O cruzamento com a década responde de forma nítida à QI2 (Figura 2). A associação é moderada e estatisticamente robusta: V de Cramér = 0,28 (qui-quadrado ≈ 484 644; n ponderado = 2 053 341). Os perfis não se distribuem uniformemente no tempo; pelo contrário, descrevem uma transição clara.

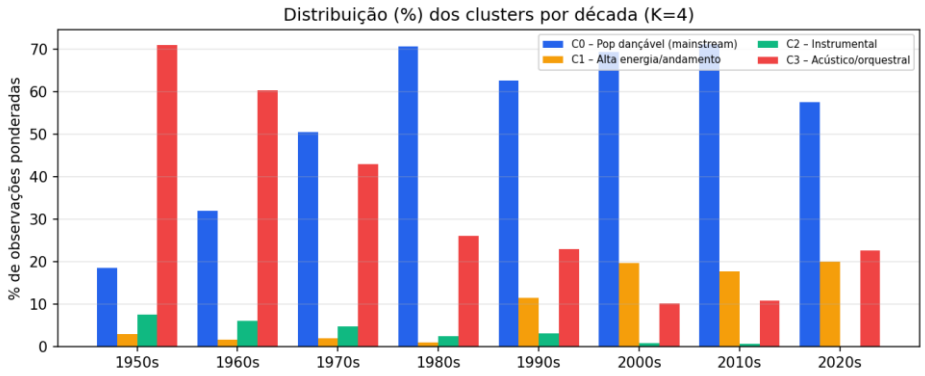


Figura 2 — Distribuição (%) de cada cluster por década (cada década soma 100%).

Nas décadas de 1950 e 1960 predomina o perfil C3 acústico/orquestral (71% em 1950 e 60% em 1960). À medida que avançam as décadas, este perfil recua de forma quase monótona (até cerca de 10% nas décadas de 2000 e 2010), cedendo lugar ao C0 pop, que passa a predominar a partir da década de 1980 (60–71%). O perfil C1 de Música agitada é praticamente residual até à década de 1980, aumentando a partir da década de 1990 (12%) e atingindo cerca de 20% nas décadas mais recentes. O perfil C2 instrumental, sempre minoritário, desaparece quase por completo (0% em 2020). Regista-se ainda um resultado inesperado: na década de 2020, o perfil C3 acústico recupera (23%), o que poderá refletir a tendência recente de pop acústico e indie, bem como o número ainda reduzido de observações dessa década.

Síntese dos resultados. Os êxitos não são sonoramente homogéneos: organizam-se em quatro perfis estáveis e interpretáveis (QI1) e a respetiva prevalência traça uma trajetória coerente da história da música popular — do registo acústico/orquestral das origens para um registo progressivamente mais dançável, produzido e enérgico (QI2).

5. Discussão

Plausibilidade. Os padrões obtidos são musicalmente plausíveis e independentes de qualquer rotulagem prévia: o recuo do registo acústico e a ascensão do registo dançável e produzido acompanham a eletrificação, a produção em estúdio e a estética de dança das últimas décadas. O facto de a estrutura emergir exclusivamente a partir das características de áudio reforça a sua credibilidade.

Resposta às questões. Ambas as questões de investigação obtêm resposta afirmativa e fundamentada: existem perfis naturais (QI1) e a respetiva composição evolui sistematicamente no tempo (QI2), com uma associação moderada (V = 0,28).

Estabilidade e ambiguidade. Nem todos os resultados apresentam a mesma nitidez. A silhueta em K=4 (0,34) indica grupos moderadamente sobrepostos, e não esferas bem separadas, o que é expectável em dados musicais, nos quais as fronteiras entre estilos são contínuas. A fronteira entre C0 (dançável) e C1 (Música agitada) é a menos estável, dado que ambos correspondem a registos modernos e a sua separação exata depende da inicialização. Em contrapartida, os perfis extremos, C3 acústico e C2 instrumental, revelam-se robustos e facilmente reconhecíveis.

Limitações. Várias decisões condicionam os resultados e devem ser lidas com prudência:

- **Ponderação e inferência.** A replicação por pesos inflaciona o n e invalida o valor-p do qui-quadrado, razão pela qual se reportou o V de Cramér. A escolha da função de ponderação (raiz quadrada) constitui uma decisão de modelação que condiciona os centróides.
- **Enviesamento do dataset.** O Hot 100 abrange apenas êxitos dos Estados Unidos, pelo que os perfis descrevem o sucesso comercial norte-americano e não a música em geral. As características do Spotify foram obtidas a posteriori e podem conter erros (na Fase 1 foram detetados casos anómalos).
- **Perda de informação.** A redução de cada música a dez médias, seguida de padronização, elimina nuances; acresce que a unidade "música-semana" favorece os êxitos de maior longevidade.
- **Dependência de parâmetros.** K=4 constitui uma solução de compromisso; outros valores de k produziriam leituras distintas, ainda que a tendência temporal global se mantivesse.

6. Conclusões

A análise não supervisionada das características de áudio dos êxitos da Billboard revelou quatro perfis sonoros interpretáveis, pop, alta energia, instrumental e acústico/orquestral, e demonstrou que a

respetiva prevalência evolui de forma sistemática ao longo das décadas (V de Cramér = 0,28). O principal contributo do trabalho consiste em traduzir um conjunto de dados de grande dimensão numa leitura clara: a música de êxito transitou de um registo acústico/orquestral para um registo dançável e produzido, emergindo a vertente de alta energia a partir da década de 1990.

As principais limitações residem na moderada separação entre os dois perfis modernos, no enviesamento do conjunto de dados para o mercado norte-americano e na dependência das opções de pré-processamento (ponderação e K). Como extensões futuras, sugere-se: a aplicação de métodos de agrupamento baseados em densidade ou de modelos de mistura gaussiana, que toleram melhor a sobreposição de grupos; a avaliação da estabilidade da solução por reamostragem (bootstrap); e o enriquecimento da unidade de análise com a duração da permanência no chart ou com o género musical.

7. Declaração sobre o uso de ferramentas de IA

No desenvolvimento do presente trabalho recorreu-se a ferramentas de IA generativa como Google Antigravity e Claude Desktop como apoio, designadamente para:

- o esclarecimento conceptual inicial de métricas de avaliação de agrupamento (silhueta, WSSSE e V de Cramér);
- a sugestão de estrutura e organização do código PySpark e dos respetivos comentários;

8. Referências

- Billboard Hot 100 — dataset «Billboard Hot weekly charts» (Data.World), aparições semanais 1958–2021.
- Spotify Audio Features — atributos de áudio obtidos via Spotify Web API (endpoint Audio Features).
- Apache Spark — MLlib: KMeans, StandardScaler, PCA, ClusteringEvaluator. Documentação oficial spark.apache.org.
- Rousseeuw, P. J. (1987). Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. J. Comp. Appl. Math.
- Cramér, H. (1946). Mathematical Methods of Statistics. Princeton University Press.
- Bibliotecas: PySpark, pandas, NumPy, SciPy (chi2_contingency), Plotly.

9. Anexos

Anexo A — Métricas de avaliação por k

k	WSSSE	Silhueta (amostra 10%)
2	18 717 837	0,667
3	15 646 821	0,315
4	13 997 227	0,339
5	13 613 391	0,206
6	12 798 639	0,214
7	11 253 307	0,249
8	10 643 856	0,236

K=4 escolhido por equilíbrio entre cotovelo do WSSSE e interpretabilidade.

Anexo B — Distribuição (%) dos clusters por década

Década	C0	C1	C2	C3
1950s	18,5	2,9	7,6	70,9
1960s	32,0	1,7	6,0	60,3
1970s	50,5	1,9	4,7	42,9
1980s	70,5	1,0	2,4	26,1
1990s	62,5	11,5	3,1	22,9
2000s	69,2	19,7	0,8	10,2
2010s	71,0	17,7	0,6	10,8
2020s	57,4	20,0	0,0	22,6

Anexo C — Notas de reprodutibilidade

- Script: PySpark_MPL09.py (kmeans_hits). Dados esperados em /BigData/Projecto/data/ (billboard.csv, audio_features.csv).
- Semente aleatória fixa (seed=42) no K-means, na amostragem da silhueta e na projeção PCA.
- Ficheiros de dados não incluídos na submissão, conforme o enunciado.